

Bericht zu Hausarbeit 1

zu 1c:

Es ist wichtig, die Normalisierung und die damit verbundene Berechnung der Standardabweichung und des Mittelwertes ausschließlich auf den Trainingsdaten zu berechnen, da sonst die Werte der Testdaten mit in das Training "sickern" würden und die Testdaten somit während des Trainings schon Einfluss auf das Modell genommen haben. Die Testdaten wären somit keine ungesesehenen neuen Daten für das Modell und dies würde die Ergebnisse verfälschen. Dieses Problem wird als Data-Leakage bezeichnet.

zu 2c:

$w = [63.97, 3.53, 0.48, 0.32, -0.18, 0.49, 1.79, 2.4, 1.22]$

Da alle Merkmale standardisiert wurden, können die geschätzten Koeffizienten direkt miteinander verglichen werden. Am meisten zur Vorhersage tragen die Merkmale bei, deren Gewichte (Koeffizienten) am höchsten sind. In diesem Fall sind dies $3.53 \times x_1$, $2.4 \times x_7$ und $1.79 \times x_6$. Dies entspricht den Merkmalen „Age“, „Value“ und „Skill Moves“. Intuitiv würde man sich auch an diesen Merkmalen am stärksten orientieren, um einen Fußballspieler zu bewerten.

Trainingsdaten: $R^2 = 0.66$, $MSE = 20.57$

Testdaten: $R^2 = 0.155$, $MSE = 51.80$

zu 3c:

Gewählte Merkmale durch Forward Stepwise Selection bei quadratischen Features:

selected = [0, 8, 1, 6, 16, 3, 7, 15, 2, 10, 4, 12, 11, 13, 14, 5, 9]

Das beste Ergebnis, beim Betrachten des Validierungsfehlers, im Verhältnis zu einer geringen Komplexität erbringt das Modell bereits mit vier der 16 Merkmale. Das Modell mit sieben Merkmalen ist geringfügig besser, während alle weiteren Modelle kaum bis keine Verbesserung erzielen.

Trainingsdaten: $R^2 = 0.74$, $MSE = 15.74$

Testdaten: $R^2 = 0.21$, $MSE = 48.30$

zu 3d:

Gewählte Merkmale durch Forward Stepwise Selection bei den neu definierten Merkmalen:

selected = [0, 8, 1, 6, 3, 9, 11, 2, 7, 12, 4, 16, 14, 13, 10, 15, 5]

Auch bei alternativen Merkmaldefinitionen werden ähnliche Basismerkmale bevorzugt, was darauf hindeutet, dass diese den größten Informationsgehalt bezüglich der Zielvariable besitzen.

zu 4b:

Das Modell zeigt auf den Trainingsdaten jeweils eine gute Anpassung mit einem geringen Fehler und einem hohen Bestimmtheitsmaß. Auf den Testdaten ist der Fehler jedoch deutlich höher, und das Bestimmtheitsmaß fällt teilweise sehr gering oder sogar leicht negativ aus. Dies deutet auf eine Überanpassung (Overfitting) der Modelle hin, insbesondere bei zunehmender Modellkomplexität durch Merkmalerweiterungen.