

H1-561874 Ergebnisbericht - Henry Mirus

KI-Disclaimer

Github-Copilot Pro wurde verwendet, um Funktionsbeschreibungen zu verfassen, Übersichtlichkeit in der Struktur des Skriptes zu gewährleisten und Verbesserungen (hinsichtlich Exception-Handling und Edge-Cases) einzubauen.

Datensatz und Split

- Datei: `H1-FIFA23.csv.gz` bzw. `H1-FIFA23.csv`
- Die gzip-Datei wird im Programm entpackt, damit ich mir die Rohdaten ansehen kann.
- Zielvariable: `Overall`
- Trainingssatz: `Set == 0`
- Holdout: `Set in (1,2)`, danach Split in Val/Test = `90/10` mit Seed `561874`
- Formen: Train `16208`, Val `1306`, Test `146`

Warum sollten Standardisierungsparameter ausschließlich aus Trainingsdaten berechnet werden?

- Sonst könnten sich Testdaten in die Trainingsdaten "einschleichen", da sie die Standardisierung beeinflussen.
- Die errechnete Standardisierung wird dann auf den Validation- und Test-Datensatz angewandt, weil das Modell mit den skalierten Werten lernt.

Basismodell (8 standardisierte Features)

- MSE Train: `20.5709`
- MSE Test: `56.3787`
- R^2 Train: `0.6629`
- R^2 Test: `-0.0119`
- Age: 3.532980 (positiver Zusammenhang)
- Height: 0.484131 (positiver Zusammenhang)
- Weight: 0.319605 (positiver Zusammenhang)
- International Reputation: -0.178245 (negativer Zusammenhang)
- Weak Foot: 0.488214 (positiver Zusammenhang)
- Skill Moves: 1.793152 (positiver Zusammenhang)
- Value: 2.402448 (positiver Zusammenhang)
- Wage: 1.215094 (positiver Zusammenhang)

Intuition

Das Alter trägt sehr viel zu dem errechneten Overall-Wert bei, was auf die Erfahrung zurückzuführen wäre, allerdings deutlich mehr als Value und Wage, was entgegen der Intuition geht. Außerdem hätte ich nicht erwartet, dass die Internationale Reputation einen negativen Zusammenhang hat, sondern eher das Gewicht. Die restlichen Merkmale und ihr Zusammenhang mit dem Overall-Wert finde ich plausibel.

Erweiterung A: Quadratische Terme (16 Features)

- MSE Train: `15.7417`
- MSE Test: `47.2674`
- R^2 Train: `0.7420`
- R^2 Test: `0.1516`

Vergleich mit Basismodell

Der MSE ist sowohl auf Trainings und Test-Datensatz geringer, was positiv ist. Die Fehler von R^2 sind auf dem Trainingsdatensatz höher, aber auf dem Testdatensatz kleiner, was insgesamt also ein besseres Modell ergibt.

FSS auf Erweiterung A

- Bestes Modell laut Test-MSE bei `11` Features:

Wage, Age, Wage², Value, Value², Skill Moves, Age², Height², Weak Foot, Weight², Height

- MSE Train: `15.7670`
- MSE Val: `47.8166`
- MSE Test: `47.1579`

Erweiterung B: Alternative 8 Merkmale (Interaktionen + log)

- Alternative Merkmale:
- 'Age*Reputation',
- 'Age*SkillMoves',
- 'Height*SkillMoves',
- 'Weight*SkillMoves',
- 'Height*Weight',
- 'WeakFoot*SkillMoves*Value',
- $\log_{10}(\text{Value})^2$,
- $\log_{10}(\text{Wage})^2$,
- MSE Train: `6.8142`

- MSE Test: `14.2421`
- R^2 Train: `0.8883`
- R^2 Test: `0.7444`

FSS auf Erweiterung B

- Bestes Modell laut Test-MSE bei `16` Features:

$\log1p(\text{Value})^2$, Age, $\log1p(\text{Wage})^2$, WeakFoot, WeakFoot*SkillMoves*Value, Age*Reputation, Height*SkillMoves, Age*SkillMoves, Wage, Value, SkillMoves, Height, Reputation, Weight*SkillMoves, Weight, Height*Weight

- MSE Train: `6.8142`
- MSE Val: `13.1920`
- MSE Test: `14.2421`
- Besseres Ergebnis als bei Erweiterung A. Es kann also sinnvoll sein gezielt Features "umzubauen", um ein besseres Modell zu erhalten.

Überanpassung

Bereits beim Basismodell erkennt man einen relativ niedrigen MSE-Train ggü. dem MSE-Test. Bei dem Modell mit quadratischen Erweiterungen wird dieser Unterschied noch größer, was an der höheren Komplexität liegt. Daraus wird ersichtlich, dass es sich hier um Überanpassung handelt. In der Grafik des FSS-Verlaufs erkennt man gut, ab wann ein Modell überangepasst ist.

Visualisierungen

- `Plots\h1\_split\_target\_distributions.png`
- `Plots\h1\_feature\_overview\_before\_after\_normalization.png`
- `Plots\h1\_diagnostics\_base\_model.png`
- `Plots\h1\_diagnostics\_quadratic\_model.png`
- `Plots\h1\_diagnostics\_alternative\_model.png`
- `Plots\h1\_fss\_mse-change\_quadratic\_model.png`
- `Plots\h1\_fss\_best\_quadratic\_model.png`
- `Plots\h1\_fss\_mse-change\_alternative\_model.png`
- `Plots\h1\_fss\_best\_alternative\_model.png`

Fazit

- Das Basismodell zeigt deutliche Generalisierungsschwierigkeiten (stark schlechter Testfehler, negatives Test- R^2).
- Quadratische Terme verbessern den Fehler gegenüber dem Basismodell, reichen aber alleine nicht für gute Generalisierung.

- Die alternative Merkmalskonstruktion (Interaktionen + log-Transformationen) liefert die beste Testleistung.
- Der FSS-Verlauf macht sichtbar, ab welcher Modellkomplexität zusätzliche Features kaum noch helfen oder überanpassen.