

H2-561874 Ergebnisbericht - Henry Mirus

KI-Disclaimer

Claude Code (Anthropic) wurde verwendet, um Funktionsbeschreibungen zu verfassen, Übersichtlichkeit in der Struktur des Skriptes zu gewährleisten und diesen Bericht zu verfassen.

Datensatz und Split (Aufgabe 1b)

- Datei: **H2-DryBeans.csv.gz**
- Zielvariable: **Class** (7 Bohnensorten)
- Merkmale: 16 geometrische Merkmale (Fläche, Umfang, Achsenlängen, Formfaktoren)
- Gesamtgröße: **13.611 Instanzen**
- Split: 80 % Training (**10.888**) / 20 % Test (**2.723**), stratifiziert mit **random_state=561874**

Klassenverteilung (stratifiziert – Anteile identisch in Train/Test)

Klasse	Gesamt	Anteil	Train	Test
BARBUNYA	1.322	9,71 %	1.057	265
BOMBAY	522	3,84 %	418	104
CALI	1.630	11,98 %	1.304	326
DERMASON	3.546	26,05 %	2.837	709
HOROZ	1.928	14,17 %	1.542	386
SEKER	2.027	14,89 %	1.621	406
SIRA	2.636	19,37 %	2.109	527

Ist der Datensatz balanciert? Nein – DERMASON (26,05 %) ist über sechsmal häufiger als BOMBAY (3,84 %); bei der Modellbewertung kann Accuracy allein irreführend sein, wenn seltene Klassen schlecht erkannt werden.

Modellvergleich (Aufgabe 2d)

GridSearchCV auf **Random Forest** (2 Parameter × 3 Werte → 9 Kombinationen × 5 Folds = 45 Fits):

- **n_estimators** ∈ {50, 100, 200}
- **max_depth** ∈ {None, 10, 20}

Modell	CV Accuracy	Std
Random Forest (Standard)	0,9981	0,0008
AdaBoost (Standard)	0,9008	0,0481
RF getunt (GridSearchCV)	0,9983	–

Beste RF-Parameter: `n_estimators=200`, `max_depth=10`

Welches Modell schneidet am besten ab? Das getunte Random-Forest-Modell mit 99,83 % CV-Accuracy.

Warum? Random Forest baut viele unkorrelierte Bäume (Bagging + zufällige Feature-Auswahl) und mittelt ihre Vorhersagen, was Varianz stark reduziert. AdaBoost nutzt standardmäßig flache Stümpfe (`max_depth=1`), die bei 16 Features und 7 Klassen zu wenig Ausdrucksstärke besitzen – erkennbar an der deutlich höheren Instabilität (Std 0,0481 vs. 0,0008). `max_depth=10` im GridSearch-Tuning begrenzt übertiefes Wachstum und dämpft marginales Overfitting.

Analyse auf Testmenge (Aufgabe 3)

Test-Accuracy (bestes RF-Modell): `0,9982` – nur 5 von 2.723 Bohnen falsch klassifiziert.

Konfusionsmatrix (Aufgabe 3a)

Visualisierung: `Plots\h2_confusion_matrix.png`

Verwechselte Klassen:

Tatsächlich	Vorhergesagt	Anzahl
DERMASON	HOROZ	2
HOROZ	DERMASON	1
SIRA	CALI	2

Die am häufigsten verwechselten Paare sind **DERMASON** ↔ **HOROZ** (3 Fehler) und **SIRA** ↔ **CALI** (2 Fehler).

Feature Importances – Top 10 (Aufgabe 3b)

Visualisierung: `Plots\h2_feature_importances.png`

Rang	Merkmal	Importance
1	EquivDiameter	0,2134
2	Perimeter	0,1292
3	MinorAxisLength	0,1198
4	ShapeFactor2	0,1087
5	ShapeFactor1	0,0898
6	Area	0,0706
7	ConvexArea	0,0589
8	MajorAxisLength	0,0470
9	ShapeFactor3	0,0398
10	AspectRatio	0,0383

Diskussion (Aufgabe 3c)

Wichtigste Merkmale: Die drei stärksten Features – **EquivDiameter** (0,21), **Perimeter** (0,13) und **MinorAxisLength** (0,12) – beschreiben allesamt die **Gesamtgröße** der Bohne. Das ist plausibel, da sich die Sorten vor allem durch ihre Größe unterscheiden: BOMBAY-Bohnen sind deutlich größer als alle anderen Sorten und lassen sich allein durch Größenmerkmale fast fehlerfrei trennen. **ShapeFactor2** und **ShapeFactor1** (Rang 4–5) kodieren das Verhältnis von Haupt- zu Nebenachse und erfassen damit die **Form** (rund vs. länglich), was zur Unterscheidung ähnlich großer Sorten wie SEKER (rund) und HOROZ (länglich) entscheidend ist.

Verwechselte Klassen: Die fünf Fehler treten ausschließlich zwischen DERMASON ↔ HOROZ und SIRA ↔ CALI auf. Beide Paare überlappen sich in Größe und Grundform, sodass der Random Forest selbst mit **max_depth=10** die feinen Unterschiede in Roundness oder Compactness in seltenen Grenzfällen nicht auflösen kann. Die insgesamt sehr geringe Fehlerquote (0,18 %) zeigt jedoch, dass die 16 geometrischen Merkmale gemeinsam sehr trennscharf sind.

Visualisierungen

- **Plots\h2_confusion_matrix.png**
- **Plots\h2_feature_importances.png**

Fazit

- Random Forest erreicht mit Standardeinstellungen bereits 99,81 % CV-Accuracy auf diesem Datensatz.
- AdaBoost (Standard) ist mit 90,08 % deutlich schwächer und instabiler (Std 0,0481), da flache Stümpfe die 7-Klassen-Trennkomplexität nicht abbilden können.
- GridSearch verbessert RF minimal auf 99,83 %; **max_depth=10** ist besser als unbegrenzte Tiefe, da es Overfitting dämpft.
- Geometrische Größenmerkmale (EquivDiameter, Perimeter, MinorAxisLength) sind am informativsten; Formfaktoren (ShapeFactor1/2) helfen bei der Feinunterscheidung ähnlich großer Sorten.