

H3-561874 Ergebnisbericht – Henry Mirus

KI-Disclaimer

Claude Code (Anthropic) wurde verwendet, um den Code zu strukturieren, Funktionsbeschreibungen zu verfassen und diesen Bericht zu erstellen.

Datensatz und Split (Aufgabe 1a)

- Datei: `H3-Wisconsin.csv.gz`
 - Zielvariable: `diagnosis` (binär: `malignant` = 1, `benign` = 0)
 - Merkmale: 30 reellwertige Features (Mittelwert, Standardfehler und „Worst“-Wert für je 10 Messgrößen)
 - Gesamtgröße: **569 Instanzen** (212 bösartig, 357 gutartig)
 - Split: 75 % Training (**426**) / 25 % Test (**143**), stratifiziert, `random_state = 561874`
 - Standardisierung: `StandardScaler` ausschließlich auf den Trainingsdaten gefittet, dann auf Test angewendet
-

Aufgabe 1 – L2-regularisierte logistische Regression (3 P.)

Methode: `LogisticRegressionCV(l1_ratios=[0.0], solver='saga', cv=5, Cs=np.logspace(-3,3,61))`

Kennzahl	Wert
Bestes C	0.158489
$\log_{10}(C)$	-0.800
Testgenauigkeit	97,90 %

Diagramm 1 (`h3_diagram1_l2_cv_accuracy.png`):

Die mittlere 5-Fold-CV-Genauigkeit steigt mit zunehmendem C (weniger Regularisierung) zunächst stark an, erreicht ein Plateau im mittleren C-Bereich und fällt danach leicht ab. Das gewählte C markiert das Maximum der CV-Kurve. Die geringe Streuung (± 1 Std.-Abw.) über die Folds zeigt, dass das Modell robust gegenüber der Datenteilung ist.

Aufgabe 2 – L1-Regularisierung und Merkmalsauswahl (4 P.)

Methode: `LogisticRegressionCV(l1_ratios=[1.0], solver='saga', cv=5, Cs=np.logspace(-3,3,61))`

Kennzahl	Wert
Bestes C	0.398107

Kennzahl	Wert
$\log_{10}(C)$	-0.400
Testgenauigkeit	97,20 %
Nicht-Null-Koeffizienten	15 / 30

Ausgewählte Merkmale ($|w_j| > 10^{-8}$):

Merkmal	Koeffizient w_j
mean texture	+0.1656
mean concave points	+0.6615
radius error	+1.2524
perimeter error	+0.0614
area error	+0.0566
compactness error	-0.0339
fractal dimension error	-0.2549
worst radius	+1.9462
worst texture	+1.0135
worst perimeter	+0.8396
worst area	+0.1756
worst smoothness	+0.5294
worst concavity	+0.2341
worst concave points	+1.4316
worst symmetry	+0.0139

Diagramm 2 ([h3_diagram2b_l1_regularization_path.png](#)):

Bei kleinem C (starke Regularisierung, links) sind nahezu alle Koeffizienten null – das Modell ignoriert fast alle Merkmale. Mit wachsendem C treten Merkmale stückweise linear in das Modell ein (charakteristisch für L1/Lasso: Koeffizienten laufen spitz in die Null hinein). Das gewählte C (schwarze Strichlinie) zeigt die Grenze zwischen sparsem und vollbesetztem Modell.

Aufgabe 3 – Vergleich und Interpretation (3 P.)

Diagramm 3 ([h3_diagram3_correlation_matrix.png](#)):

Die Korrelationsmatrix (= Kovarianzmatrix der standardisierten Trainingsdaten, $\mathbf{X}_{\text{std}}^T \mathbf{X}_{\text{std}} / (n - 1)$) zeigt deutlich ausgeprägte Blocks hoher Korrelation: Die Merkmale *mean radius*, *mean perimeter* und *mean*

area – ebenso ihre „SE“- und „Worst“-Versionen – korrelieren stark untereinander (Werte nahe +1), da sie alle die Tumorgroße beschreiben.

Diskussion:

Lasso (L1) wählt aus jeder Gruppe stark korrelierter Merkmale typischerweise nur **einen Repräsentanten** aus und setzt die übrigen auf null, da die L1-Strafe keine Präferenz für Gleichverteilung hat (im Gegensatz zu Ridge/L2). Das ist in den Ergebnissen erkennbar: Von den drei eng verwandten Größenmerkmalen (*mean radius*, *mean perimeter*, *mean area*) und deren Pendant-Varianten tauchen meist nur einzelne im finalen Modell auf.

Dies illustriert sowohl die **Stärke** als auch die **Schwäche** von Lasso für Interpretierbarkeit:

- **Vorteil:** Das Modell wird sehr kompakt – nur wenige Merkmale müssen erklärt werden.
- **Nachteil:** Welcher Repräsentant aus einer korrelierten Gruppe gewählt wird, ist nahezu zufällig und kann sich bei kleinen Datenänderungen stark verschieben. Die nicht ausgewählten Merkmale sind deshalb *nicht* irrelevant, sondern nur redundant zum gewählten Repräsentanten.

Insgesamt verbessert Lasso die **Interpretierbarkeit** des Modells erheblich (von 30 auf wenige aktive Merkmale), ohne die Vorhersagegenauigkeit wesentlich zu verschlechtern, da die eliminierten Merkmale durch ihre korrelierten Stellvertreter im Modell implizit abgedeckt werden.

Visualisierungen

- *Plots/h3_diagram1_l2_cv_accuracy.png* – L2 CV-Kurve
- *Plots/h3_diagram2a_l1_cv_accuracy.png* – L1 CV-Kurve
- *Plots/h3_diagram2b_l1_regularization_path.png* – L1 Regularisierungspfad
- *Plots/h3_diagram3_correlation_matrix.png* – Korrelationsmatrix