

H3-561874 Ergebnisbericht – Henry Mirus

KI-Disclaimer

Claude Code (Anthropic) wurde verwendet, um den Code zu strukturieren, Funktionsbeschreibungen zu verfassen und diesen Bericht zu erstellen.

Datensatz und Split (Aufgabe 1a)

- Datei: `H3-Wisconsin.csv.gz`
 - Zielvariable: `diagnosis` (binär: `malignant` = 1, `benign` = 0)
 - Merkmale: 30 reellwertige Features (Mittelwert, Standardfehler und „Worst“-Wert für je 10 Messgrößen)
 - Gesamtgröße: **569 Instanzen** (212 bösartig, 357 gutartig)
 - Split: 75 % Training (**426**) / 25 % Test (**143**), stratifiziert, `random_state = 561874`
 - Standardisierung: `StandardScaler` ausschließlich auf den Trainingsdaten gefittet, dann auf Test angewendet
-

Aufgabe 1 – L2-regularisierte logistische Regression (3 P.)

Methode: `LogisticRegressionCV(l1_ratios=[0.0], solver='saga', cv=5, Cs=np.logspace(-3,3,61))`

Kennzahl	Wert
Bestes C	0.251189
$\log_{10}(C)$	-0.600
Testgenauigkeit	98,60 %

Diagramm 1 (`h3_diagram1_l2_cv_accuracy.png`):

Die mittlere 5-Fold-CV-Genauigkeit steigt mit zunehmendem C (weniger Regularisierung) zunächst stark an, erreicht ein Plateau im mittleren C-Bereich und fällt danach leicht ab. Das gewählte C markiert das Maximum der CV-Kurve. Die geringe Streuung (± 1 Std.-Abw.) über die Folds zeigt, dass das Modell robust gegenüber der Datenteilung ist.

Aufgabe 2 – L1-Regularisierung und Merkmalsauswahl (4 P.)

Methode: `LogisticRegressionCV(l1_ratios=[1.0], solver='saga', cv=5, Cs=np.logspace(-3,3,61))`

Kennzahl	Wert
Bestes C	0.199526

Kennzahl	Wert
$\log_{10}(C)$	-0.700
Testgenauigkeit	96,50 %
Nicht-Null-Koeffizienten	10 / 30

Ausgewählte Merkmale ($|w_j| > 10^{-8}$):

Merkmal	Koeffizient w_j
mean texture	+0.0080
mean concave points	+0.4420
radius error	+0.8004
fractal dimension error	-0.0133
worst radius	+2.2588
worst texture	+0.9285
worst perimeter	+0.1297
worst smoothness	+0.3672
worst concavity	+0.0473
worst concave points	+1.3557

Diagramm 2 (h3_diagram2b_l1_regularization_path.png):

Bei kleinem C (starke Regularisierung, links) sind nahezu alle Koeffizienten null – das Modell ignoriert fast alle Merkmale. Mit wachsendem C treten Merkmale stückweise linear in das Modell ein (charakteristisch für L1/Lasso: Koeffizienten laufen spitz in die Null hinein). Das gewählte C (schwarze Strichlinie) zeigt die Grenze zwischen sparsem und vollbesetztem Modell.

Aufgabe 3 – Vergleich und Interpretation (3 P.)

Diagramm 3 (h3_diagram3_correlation_matrix.png):

Die Korrelationsmatrix (= Kovarianzmatrix der standardisierten Trainingsdaten, $\mathbf{X}_{\text{std}}^T \mathbf{X}_{\text{std}} / (n - 1)$) zeigt deutlich ausgeprägte Blocks hoher Korrelation: Die Merkmale *mean radius*, *mean perimeter* und *mean area* – ebenso ihre „SE“- und „Worst“-Versionen – korrelieren stark untereinander (Werte nahe +1), da sie alle die Tumorgroße beschreiben.

Diskussion:

Die Korrelationsmatrix zeigt starke Blöcke: *mean radius*, *mean perimeter* und *mean area* korrelieren nahezu perfekt miteinander ($r \approx +0,99$), ebenso ihre „SE“- und „Worst“-Varianten – alle beschreiben die physische Größe der Zellkerne.

Lasso setzt aus diesen korrelierten Gruppen typischerweise alle bis auf einen Repräsentanten auf null. Tatsächlich eliminiert das Modell die gesamte „mean“-Größengruppe (`mean radius`, `mean perimeter`, `mean area` alle null) sowie `perimeter error`, `area error` und `compactness error` und behält stattdessen die informativer erscheinenden „worst“-Versionen (`worst radius`, `worst perimeter`, `worst concavity`, `worst concave points`) sowie `radius error` als Stellvertreter der Größengruppe bei.

Dabei tritt aber auch eine bekannte Instabilität von Lasso zutage: Innerhalb der „worst“-Gruppe werden mehrere korrelierte Merkmale gleichzeitig beibehalten (`worst radius`, `worst perimeter`, `worst texture`), da Lasso bei schwächerer Regularisierung (größerem C) ganze korrelierte Blöcke ins Modell aufnehmen kann. Welche Variante bei strengerer Regularisierung übrig geblieben wäre, hängt von kleinen Datenschwankungen ab.

Insgesamt verbessert Lasso die **Interpretierbarkeit** erheblich (30 → 10 aktive Merkmale, 96,50 % Testgenauigkeit gegenüber 98,60 % bei Ridge), mit einem geringen Genauigkeitsverlust, da eliminierte Merkmale durch ihre korrelierten Stellvertreter implizit abgedeckt bleiben.

Visualisierungen

- `Plots/h3_diagram1_l2_cv_accuracy.png` – L2 CV-Kurve
- `Plots/h3_diagram2a_l1_cv_accuracy.png` – L1 CV-Kurve
- `Plots/h3_diagram2b_l1_regularization_path.png` – L1 Regularisierungspfad
- `Plots/h3_diagram3_correlation_matrix.png` – Korrelationsmatrix