

H3-561874 Ergebnisbericht – Henry Mirus

KI-Disclaimer

Claude Code (Anthropic) wurde verwendet, um den Code zu strukturieren, Funktionsbeschreibungen zu verfassen und diesen Bericht zu erstellen.

Datensatz und Split (Aufgabe 1a)

- Datei: **H3-Wisconsin.csv.gz**
 - Zielvariable: **diagnosis** (binär: **malignant** = 1, **benign** = 0)
 - Merkmale: 30 reellwertige Features (Mittelwert, Standardfehler und „Worst“-Wert für je 10 Messgrößen)
 - Gesamtgröße: **569 Instanzen** (212 bösartig, 357 gutartig)
 - Split: 75 % Training (**426**) / 25 % Test (**143**), stratifiziert, **random_state = 561874**
 - Standardisierung: **StandardScaler** ausschließlich auf den Trainingsdaten gefittet, dann auf Test angewendet
-

Aufgabe 1 – L2-regularisierte logistische Regression (3 P.)

Methode: `LogisticRegressionCV(l1_ratios=[0.0], solver='saga', cv=5, Cs=np.logspace(-3,3,61))`

Kennzahl	Wert
Bestes C	0.158489
$\log_{10}(C)$	-0.800
Testgenauigkeit	97,90 %

Diagramm 1 (**h3_diagram1_l2_cv_accuracy.png**):

Die mittlere 5-Fold-CV-Genauigkeit steigt mit zunehmendem C (weniger Regularisierung) zunächst stark an, erreicht ein Plateau im mittleren C-Bereich und fällt danach leicht ab. Das gewählte C markiert das Maximum der CV-Kurve. Die geringe Streuung (± 1 Std.-Abw.) über die Folds zeigt, dass das Modell robust gegenüber der Datenteilung ist.

Aufgabe 2 – L1-Regularisierung und Merkmalsauswahl (4 P.)

Methode: `LogisticRegressionCV(l1_ratios=[1.0], solver='saga', cv=5, Cs=np.logspace(-3,3,61))`

Kennzahl	Wert
Bestes C	0.398107

Kennzahl	Wert
$\log_{10}(C)$	-0.400
Testgenauigkeit	97,20 %
Nicht-Null-Koeffizienten	15 / 30

Ausgewählte Merkmale ($|w_j| > 10^{-8}$):

Merkmal	Koeffizient w_j
mean texture	+0.1656
mean concave points	+0.6615
radius error	+1.2524
perimeter error	+0.0614
area error	+0.0566
compactness error	-0.0339
fractal dimension error	-0.2549
worst radius	+1.9462
worst texture	+1.0135
worst perimeter	+0.8396
worst area	+0.1756
worst smoothness	+0.5294
worst concavity	+0.2341
worst concave points	+1.4316
worst symmetry	+0.0139

Diagramm 2 (h3_diagram2b_l1_regularization_path.png):

Bei kleinem C (starke Regularisierung, links) sind nahezu alle Koeffizienten null – das Modell ignoriert fast alle Merkmale. Mit wachsendem C treten Merkmale stückweise linear in das Modell ein (charakteristisch für L1/Lasso: Koeffizienten laufen spitz in die Null hinein). Das gewählte C (schwarze Strichlinie) zeigt die Grenze zwischen sparsen und vollbesetztem Modell.

Aufgabe 3 – Vergleich und Interpretation (3 P.)

Diagramm 3 (h3_diagram3_correlation_matrix.png):

Die Korrelationsmatrix (= Kovarianzmatrix der standardisierten Trainingsdaten, $\mathbf{X}_{\text{std}}^T \mathbf{X}_{\text{std}} / (n - 1)$) zeigt deutlich ausgeprägte Blocks hoher Korrelation: Die Merkmale *mean radius*, *mean perimeter* und *mean*

area – ebenso ihre „SE“- und „Worst“-Versionen – korrelieren stark untereinander (Werte nahe +1), da sie alle die Tumorgröße beschreiben.

Diskussion:

Die Korrelationsmatrix zeigt starke Blöcke: *mean radius*, *mean perimeter* und *mean area* korrelieren nahezu perfekt miteinander ($r \approx +0,99$), ebenso ihre „SE“- und „Worst“-Varianten — alle beschreiben die physische Größe der Zellkerne.

Lasso setzt aus diesen korrelierten Gruppen typischerweise alle bis auf einen Repräsentanten auf null. Tatsächlich eliminiert das Modell die gesamte „mean“-Größengruppe (*mean radius*, *mean perimeter*, *mean area* alle null) und behält stattdessen die informativer erscheinenden „worst“- und „error“-Versionen (*worst radius*, *worst perimeter*, *worst area*, *radius error*, *perimeter error*, *area error*), die für die Beurteilung von Malignität klinisch relevanter sind.

Dabei tritt aber auch eine bekannte Instabilität von Lasso zutage: Innerhalb der „worst“-Gruppe werden alle drei stark korrelierten Merkmale gleichzeitig beibehalten (kein einzelner Repräsentant gewählt), da Lasso bei schwächerer Regularisierung (größerem C) ganze korrelierte Blöcke ins Modell aufnehmen kann. Welche Variante bei strengerer Regularisierung übrig geblieben wäre, hängt von kleinen Datenschwankungen ab.

Insgesamt verbessert Lasso die **Interpretierbarkeit** erheblich (30 → 15 aktive Merkmale, 97,20 % Testgenauigkeit gegenüber 97,90 % bei Ridge), ohne nennenswerte Genauigkeitsverluste, da eliminierte Merkmale durch ihre korrelierten Stellvertreter implizit abgedeckt bleiben.

Visualisierungen

- *Plots/h3_diagram1_l2_cv_accuracy.png* – L2 CV-Kurve
- *Plots/h3_diagram2a_l1_cv_accuracy.png* – L1 CV-Kurve
- *Plots/h3_diagram2b_l1_regularization_path.png* – L1 Regularisierungspfad
- *Plots/h3_diagram3_correlation_matrix.png* – Korrelationsmatrix