

Hausarbeit 3: Regularisierungstechniken

Abgabefrist: 2026-06-29 23:59:59

Yassen Assenov

2026-06-15

Organisatorisches

- **Gesamtpunktzahl:** 10 Punkte
- **Abgabe:** Ein lauffähiges Python-Skript mit allen Berechnungen und Visualisierungen, sowie ein kurzer Bericht (max. 2 Seiten). Wenn Ihre Matrikelnummer 123456 ist, sollten die Dateinamen `H3-123456.py` und `H3-123456.pdf` sein.
- **Erlaubte Bibliotheken:** Ausschließlich `matplotlib`, `numpy` und `sklearn`. Die Verwendung weiterer Bibliotheken ist **nicht** gestattet.
- **Datensatz:** Die Datei `H3-Wisconsin.csv.gz` ist auf der Kursseite bereitgestellt. Die Originaldaten stammen vom UCI Machine Learning Repository.^a

^a<https://archive.ics.uci.edu/dataset/17/breast+cancer+wisconsin+diagnostic>

Hintergrund

Wir verwenden den *Breast Cancer Wisconsin* Datensatz. Er ist zwar direkt über `sklearn` verfügbar, aber er sollte in dieser Hausarbeit aus einer lokalen Datei geladen werden. Es handelt sich um eine binäre Klassifikationsaufgabe (212 bösartige vs. 357 gutartige Tumorproben) mit 569 Beobachtungen und 30 reellwertigen Merkmalen. Ziel dieser Hausarbeit ist es, mithilfe von Regularisierungstechniken ein zuverlässig und interpretierbares Klassifikationsmodell zu entwickeln.

Aufgabe 1: L2-regularisierte logistische Regression (3 P.)

- Laden Sie die Datei `H3-Wisconsin.csv.gz`. Teilen Sie den Datensatz in einen Trainingsatz (75 %) und einen Testsatz (25 %) auf. Verwenden Sie dabei Ihre Matrikelnummer als `random_seed` und sorgen Sie für eine stratifizierte Aufteilung (gleiche Klassenanteile in beiden Sätzen). Standardisieren Sie anschließend die Merkmale.
- Trainieren Sie eine L2-regularisierte logistische Regression. Wählen Sie das beste C per 5-facher Kreuzvalidierung auf einem Gitter von $C \in [10^{-3}, 10^3]$
- Berichten Sie das gewählte C und die resultierende Testgenauigkeit.
- Diagramm 1:** Plotten Sie die mittlere CV-Genauigkeit als Funktion von $\log_{10}(C)$ und markieren Sie den gewählten Wert, z. B. mit einer vertikalen Linie. Schreiben Sie 1–2 Sätze zur Interpretation.

Tipps: `LogisticRegression` oder `LogisticRegressionCV`; `np.logspace(-3, 3, 61)`.

Aufgabe 2 – L1-Regularisierung und Merkmalsauswahl (4 P.)

- Wiederholen Sie Aufgabe 1 mit *L1-Regularisierung*. Verwenden Sie denselben Train/Test-Split, dieselben standardisierten Daten und dasselbe C -Gitter wie in Aufgabe 1.

2. Berichten Sie das gewählte C , die Testgenauigkeit, die Anzahl der von Null verschiedenen Koeffizienten ($|w_j| > 10^{-8}$) sowie die Namen der zugehörigen ausgewählten Merkmale.
3. **Diagramm 2:** Plotten Sie den *Regularisierungspfad* – den Koeffizientenwert jedes Merkmals als Funktion von $\log_{10}(C)$, alle Kurven in einer einzigen Grafik. Markieren Sie das gewählte C . Schreiben Sie 1–2 Sätze zur Interpretation.

Tipp: `model.coefs_paths_`

Aufgabe 3 – Vergleich und Interpretation

(3 P.)

1. **Diagramm 3:** Berechnen und visualisieren Sie die Korrelationsmatrix des Trainingsdatensatzes. Sie ist identisch mit der Kovarianzmatrix des standardisierten Trainingsdatensatzes.
2. Diskutieren Sie in wenigen Sätzen: Welche Merkmale hat Lasso ausgewählt? Sehen Sie Hinweise darauf, dass aus stark korrelierten Merkmalsgruppen jeweils nur ein Repräsentant übrig bleibt? Was sagt das über die Eignung von Lasso zur Verbesserung der Interpretierbarkeit aus?

Tipp: `Axes.matshow` oder `Axes.imshow`